

CNN 강우여부 분류기를 적용한 ANN 기반 X-Band 레이다 유의파고 보정 Estimation of Significant Wave Heights from X-Band Radar Based on ANN Using CNN Rainfall Classifier

김희연* · 안경모** · 오찬영***

Heeyeon Kim*, Kyungmo Ahn** and Chanyeong Oh***

요지 : 항해용 X-band 레이다를 이용한 파랑관측은 해수면에 후방산란된 전자기와 이미지를 분석하여 이루어진다. 1분당 42개의 해수면 시계열 이미지로부터 3차원 FFT를 계산하고 변조전달함수(Modulation Transfer Function)를 구하여 파랑정보를 추출한다. 따라서 레이다 파고계로 측정한 유의파고의 정확도는 X-band 레이다 영상의 상태에 따라 결정된다. 2020년 여름 태풍 마이삭과 하이선 내습 시 강릉 안인 해안에 설치된 X-band 레이다 파고계로 관측한 유의파고의 오차가 크게 발생하였다. 이는 태풍 내습 시 급격히 유의파고가 증가하는 한편 강한 강우가 동반되어 X-band 레이다 영상의 품질이 저하되었기 때문이다. 최대 오차 발생 이전까지 많은 강우가 있었음이 확인된다. 본 연구에서는 convolution neural network(CNN)을 이용하여 레이다 이미지로부터 강우 여부를 분류하고 강우여부에 따라 강우시 인공신경망 모델을 적용하여 태풍 시 유의파고 관측 정확도를 향상시켰다. 폭우를 동반한 태풍 시 레이다 자료 특성에 기반하여 인공신경망 유의파고 산출 알고리즘을 개선하고 이를 통해 X-band 레이다 파고계의 정확도를 향상시키는 방법을 제시하였다.

핵심용어 : X-band 레이다, 유의파고, 머신러닝, 인공신경망, 합성곱신경망

Abstract : Wave observations using a marine X-band radar are conducted by analyzing the backscattered radar signal from sea surfaces. Wave parameters are extracted using Modulation Transfer Function obtained from 3D wave number and frequency spectra which are calculated by 3D FFT of time series of sea surface images (42 images per minute). The accuracy of estimation of the significant wave height is, therefore, critically dependent on the quality of radar images. Wave observations during Typhoon Maysak and Haishen in the summer of 2020 show large errors in the estimation of the significant wave heights. It is because of the deteriorated radar images due to raindrops falling on the sea surface. This paper presents the algorithm developed to increase the accuracy of wave heights estimation from radar images by adopting convolution neural network(CNN) which automatically classify radar images into rain and non-rain cases. Then, an algorithm for deriving the H_s is proposed by creating different ANN models and selectively applying them according to the rain or non-rain cases. The developed algorithm applied to heavy rain cases during typhoons and showed critically improved results.

Keywords : X-band marine radar, significant wave heights, machine learning, artificial neural network(ANN), convolutional neural network(CNN)

1. 서론

X-band 레이다 파고계는 원격관측 파랑 관측 장비로서 신뢰성 있는 파랑관측을 위해 지속적으로 개발되어 왔다. 기존의 초음파식 파고계, 압력식 파고계 그리고 해상 파고부이는 해저 또는 해상에 설치되어 기상 악화 시 파손이나 분실의 위험이 커 유지관리 비용이 크고 장비가 설치되어 있는 한 지점의

파랑 정보만을 측정하는 한계가 있다. 반면 X-band 레이다 파고계는 육지나 구조물에 설치할 수 있으므로 해상 환경의 영향을 받지 않아 유지관리가 용이하며, 넓은 면적을 스캔하여 해상의 면적 파랑 정보를 얻을 수 있다. Alpers and Hesselmann (1982)은 레이다 영상의 신호대잡음비(SNR: Signal to Noise ratio)의 제곱근과 유의파고가 선형관계임을 보였다. 그러나 레이다 영상의 신호대잡음비와 유의파고간의 상관성은 기상 상

*한동대학교 공간설계공학과 대학원생(Graduate Student, Department of Spatial Design & Engineering, Handong Global University)

**한동대학교 공간환경시스템공학부 교수(Corresponding author: Kyungmo Ahn, Professor, School of Spatial Environment System Engineering, Handong Global University, Handong-ro, 558, Pohang, Kyeongbuk 37554, Korea, Tel: +82-54-260-1421, kmahn@handong.edu)

***한동대학교 건설환경연구소 전임연구원(Associate Research Engineer, Institute of Construction & Environmental Research, Handong Global University)

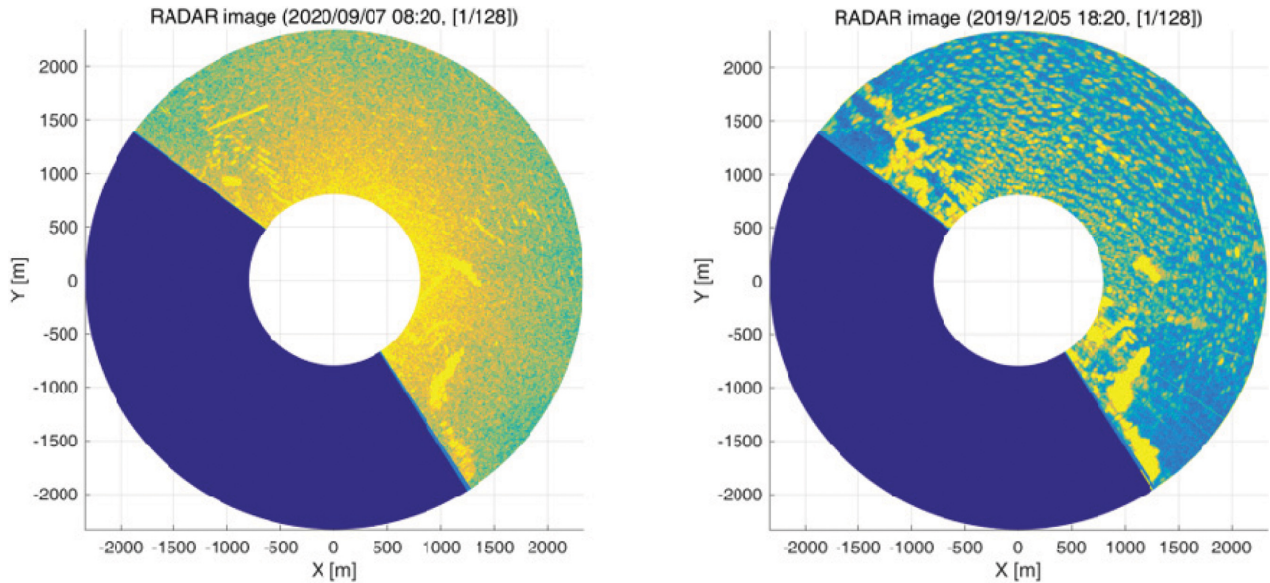


Fig. 1. X-band radar images contaminated by the influence of rain drops (left) and clear X-band radar image without rain (right).

황에 따라 달라지기 때문에 신호대잡음비의 제곱근과 유의파고의 선형관계만을 이용하여 계산한 유의파고는 그 정확도가 낮다. 특히 강우시에는 X-band 레이다 파고계의 유의파고 정확도가 크게 낮아진다. 이는 (1) 대기 중의 빗방울로 인한 전파간섭과 (2) 해수면에 떨어진 빗방울로 발생한 잔물결로 인해 레이다 신호가 무작위적으로 산란되어 레이다 영상에 잡음이 증가하기 때문이다. Fig. 1의 왼쪽 레이다 영상은 강우잡음이 나타난 영상으로 해당 시점의 유의파고는 2.8m이며 해당일의 일강수량은 166 mm이다. Fig. 1의 오른쪽 레이다 영상을 획득한 시점의 유의파고는 1.7m이며 강우가 없는 경우의 일반적인 레이다 영상이다.

Ahn et al.(2014)은 유의파고 추정시 레이다 영상의 신호대잡음비와 함께 레이다 영상을 분석하여 얻은 침투주기를 인수로 하는 비선형 관계식을 사용하여 향상된 유의파고 산정 결과를 얻었다. 또한 Vicen-Bueno et al.(2012)과 Park et al.(2017)은 머신러닝 기법 중 인공신경망(Artificial Neural Network, ANN)을 도입한 유의파고 추정 모델을 제안하였다. 레이다 영상 스펙트럼 분석을 통해 얻은 파랑 정보를 입력 변수로 하는 인공신경망 유의파고 추정 모델은 유의파고 정확도가 상당히 높아짐을 보여주었으나 상기 연구들은 강우에 의한 잡음과 이에 따른 유의파고 측정오차에 대한 고려가 부족한 한계가 있다.

한편, X-band 레이다 영상에 경험적모드분해(EMD: Empirical Mode Decomposition)를 이용하여 유의파고, 파향, 유속 등을 산정하는 연구가 수행된 바 있다(Huang et al., 1998; Liu et al., 2016a, 2016b). Liu et al.(2016a)은 EMD 분석 방식을 적용하여 강우로 오염된 X-band 레이다 영상에서 개선된 풍향 관측결과를 도출한 바 있다. 또한 Liu et al.(2016b)은 기상 상황으로 인해 오염된 레이다 관측자료에 EMD를 적용하여 강우로 인해 품질이 낮은 레이다 영상은 제거하고 파랑 분석을

시도한 바 있다. 또한 파랑 원격관측 HF radar(High Frequency Radar), MWR(MIROS Wave and Current Radar) 그리고 X-band 레이다 등의 관측자료의 품질개선 및 품질관리에 관한 다양한 연구가 지속적으로 수행되어 오고 있다(Gomez et al., 2014; Gurgel et al., 2011; Hisaki, 2009; Jun et al., 2020).

본 연구에서는 강우잡음이 발생한 레이다 영상을 파랑 분석에서 배제하지 않고 실시간으로 유의파고 산정이 가능하도록 ANN 모델 기반 유의파고 추정 알고리즘을 개발하였다. 이를 위해 X-band 레이다 영상으로부터 자동으로 강우여부를 분류하는 합성곱신경망(Convolutional Neural Network, CNN)모델을 개발하였으며, 강우여부에 따라 서로 다른 인공신경망 모델을 이용하여 유의파고를 추정하는 인공신경망 모델을 개발하였다.

2. 연구 방법

2.1 분석자료

X-band 레이다 영상에는 레이다 설치 위치로부터 반경 약 2 km 이내 범위의 해수면에서 후방 산란된 해면 클러터(Sea clutter)가 나타나며, 해면 클러터가 나타난 레이다 영상을 스펙트럼 분석하여 침투주기, 파향 그리고 유속 등 다양한 파랑 정보를 얻을 수 있다(Alpers and Hasselmann, 1982; Nieto et al., 2004).

본 연구에서는 강릉 안인 해안에 위치한 메이플비치 호텔 옥상에 X-band 레이다를 설치하여 해면 클러터를 관측한 레이다 영상을 분석하였다. 2018년 11월부터 2020년 9월까지 수집된 총 79,843개 X-band 레이다 영상을 분석하였다. 한 개의 관측 영상은 3분 길이의 레이다 이미지 128장으로 구성된다. 2019년 6월 30일 이전 자료는 20분 간격으로, 그 이

Table 1. Specification of X-band radar system

RPM	Δt	Δr	$\Delta \theta$	Maximum range	Record length
42	1.42 sec	1.5 m	0.3°	2.33 km	183 or 366 sec



Fig. 2. Location and observation range of X-band radar (Gangneung Anin beach).

후 자료는 10분 간격으로 수집하였다. 강릉 안인해안에 설치된 유의파고 추정을 위한 X-band 레이더 시스템의 시간 분해능과 공간 분해능은 Table 1에 나타내었다.

한편, 보정을 위한 참조자료로 기상청에서 제공하는 유의파고를 사용하였다. X-band 레이더 설치지점과 약 8 km 떨어진 경포대 해수욕장 해양관측부이의 5분 간격 실시간 자료를 이상값 제거 및 이동시간평균하여 보정에 사용하였다. 국립해양조사원에서 실시간으로 제공되는 5분 간격 부이관측 자료는 품질처리를 하여 일개월 후에 1시간 간격으로 제공된다. 따라서 5분 관측자료는 품질처리 후 제공되는 1시간 간격 자료보다 정확도는 떨어지나, 10분 간격으로 관측되는 레이더 자료와의 비교를 위해 5분 간격자료를 이동시간평균하여 사용하였다. X-band 레이더 시스템과 해양관측부이의 설치 지점과 레이더 관측 범위를 Fig. 2에 나타내었다.

2.2 파랑 스펙트럼

X-band 레이더를 이용한 파랑관측은 전자기파가 해수면에서 후방산란 되어 생성되는 이미지를 분석함으로써 가능하다. 관측을 통해 얻어진 레이더 영상은 해수면에서 반사된 신호의 3차원 (x, y, t) 시공간 좌표 데이터이며, 이는 3차원 푸리에변환을 통해 주파수 영역의 스펙트럼으로 변환된다. 스펙트럼에 대역통과필터(Band Pass Filter)를 적용하여 파랑성분을 추출하고 변조전달함수(Modulation Transfer Function)를 계산하여 파랑 성분 파워 스펙트럼을 구할 수 있으며, 이를 통해 파랑신호(signal), 비파랑 잡음(noise), 신호대잡음비(SNR) 등 다양한 파랑 정보를 계산한다. 파랑 성분 파워 스펙트럼을 적분하여 파랑관련 신호(signal)를 계산하고, 변조 전 전체 파워 스펙트럼의 적분값과 신호의 차를 구해 잡음(noise)

을 계산할 수 있으며 신호와 잡음의 비로 SNR(signal to noise ratio)를 계산한다. 또한 3차원 스펙트럼을 주파수 또는 2차원 파수에 대해 적분하여 각각 파수 스펙트럼, 주파수 스펙트럼 등을 얻을 수 있다. 주파수 스펙트럼으로부터 침두주기(Tp) 그리고 3차원 스펙트럼의 파수 정보로부터 파향(Pdir)을 구할 수 있다. 계산한 파랑 정보들의 시계열 자료는 유의파고 산정을 위한 ANN 모델 학습 시에 입력 자료로 사용된다.

이처럼 X-band 레이더를 이용한 파랑관측은 레이더 영상의 품질에 의존한다. 바람이 잘 불어 파랑 표면에 잔물결이 일어날 경우 잔물결의 파장이 레이더 전자기파의 파장의 대략 절반에 가까울 때 브래그 공명 조건이 만족되면서 후방산란 되는 신호의 세기가 증폭된다. 이 경우 파랑이 보다 더 선명히 나타나는 레이더 영상을 얻을 수 있으며 스펙트럼 분석을 통해 비교적 정확한 파랑 정보를 구할 수 있다. 일반적으로 바람이 잘 불지 않을 때에는 수신되는 레이더 신호의 세기가 약하기 때문에 레이더 유의파고가 낮게 과소평가되어 나타나는 경향이 있고, 강우시 빔방울로 인해 레이더 영상에 잡음이 많이 발생할 경우 레이더 유의파고의 오차가 상당히 커지는 문제가 발생한다. 전자의 경우인 바람이 불지 않아 해수면에 잔물결이 없어서 브래그 공명이 일어나지 않아 유의파고가 과소평가되는 경우는 본 연구진의 선행연구에서 레이더 영상의 품질을 평가하는 변수 $R_{val} > k$ 를 도입하여 유의파고 추정의 정확도를 향상시킨 바 있다(Park et al., 2020).

2.3 기계학습(Machine Learning)의 기본적 이론

기계학습(Machine learning)은 입력 자료와 출력 자료를 함께 학습해주면 입출력 자료 기반으로 컴퓨터가 자동으로 함수를 만들어 주는 블랙박스과 같이 작동한다. 따라서 함수식

을 정의하기 어려운 비선형 문제에 뛰어난 성능을 나타내지만, 학습된 모델의 물리적 특성을 해석하기는 어려운 한계가 있다. 기계학습으로 해결할 수 있는 문제의 유형은 대표적으로 분류 문제와 회귀 문제가 있는데 분류 문제는 데이터가 속한 집단을 선택하여 출력값으로 나타내며, 회귀 문제는 입력 데이터의 특성에 기반하여 연속적인 값을 출력값으로 나타낸다. 본 연구에서 X-band 레이더 영상을 강우 시 또는 비강우 시로 분류하기 위해 CNN을 사용한 것은 전자에 해당하며, 레이더 영상 스펙트럼 분석을 통해 얻은 파랑 변수를 학습하여 유의파고 결과를 얻기 위해 ANN을 사용한 것은 후자에 해당한다.

분류 대상이 되는 입력 데이터와 각 데이터의 집단값(분류의 경우) 또는 수치값(회귀의 경우)을 미리 알고 있는 데이터를 사용하여, 해당 데이터에 정답을 가르쳐 주면서 모델을 학습하는 방식을 지도학습(Supervised learning)이라고 한다. 따라서 지도학습을 통해 모델을 생성하기 위해서는 학습용 데이터셋과 그 정답값(label)을 필요로 하며, 일반적으로 분석용으로 수집한 데이터의 80~90%를 학습용으로 사용하고, 10~20%의 데이터를 시험 및 검증용으로 사용하여 모델의 정확도를 평가한다. 본 연구에서는 CNN과 ANN 모두 검증용 데이터를 구별하여 정확도를 검증하지 않고, 일부 자료로 학습한 모델에 전체 분석 자료를 적용한 결과로 정확도를 평가하였다.

2.4 합성곱 신경망을 이용한 강우여부 분류

합성곱 신경망(Convolutional Neural Network, CNN)은 영상 분류에 높은 성능을 나타내는 것으로 알려진 딥러닝 기술의 하나로써 일반적인 인공신경망이 입력 데이터를 1차원 벡터로 처리하는 반면 CNN은 영상에서 주변 픽셀들과의 연관성을 학습하기 때문에 대상 물체에 회전, 변형이 있거나 크기가 달라지는 경우에도 높은 분류 정확도를 나타낸다.

CNN 모델 학습과정은 입력(input), 특징추출(feature extraction), 분류(classification), 그리고 출력(output)의 과정을 포함한다. 영상이 입력되면 합성곱층(Convolution layer)에서 가중치 필터를 생성하여 필터와 영상 간 반복적으로 합

성곱 연산을 수행하여 영상의 특징을 추출한 특징맵을 만든다. 하위 추출(subsampling) 과정을 통해 추출된 특징맵의 크기를 줄여 불필요한 정보를 없애고 잡음을 제거할 수 있다. 합성곱층과 하위 추출층을 몇 차례 반복한 후, 분류 단계에서 일반적인 인공신경망 구조와 같이 1차원 벡터로 나열한 후 여러 개의 신경망 노드에 연결된 완전연결층(Fully-connected layer)을 사용하여 출력값을 다시 얻게 된다. 그 출력 값에 softmax 함수를 적용하여 각 결과 범주에 속할 확률값을 얻을 수 있고, 확률값이 가장 큰 범주를 최종적으로 선택한다.

본 연구에서는 이 CNN 모델을 사용하여 X-band 레이더 영상으로부터 강우 여부를 자동으로 분류하여 그 분류 결과를 ANN 기반 유의파고 추정 과정에 적용하고자 하였다. CNN 모델은 Fig. 3에 표현된 것과 같이 가장 단순한 형태의 구조로 구성하였다. 합성곱층과 풀링층이라고 불리는 하위 추출층을 2회씩 반복한 후 완전연결층과 log-softmax 함수를 사용하여 강우시 또는 비강우시의 두 개 결과 중 확률이 높은 값 한 개가 최종 출력되도록 하였다. 분류할 영상 입력 데이터는 X-band 레이더 영상에서 장애물이 나타나지 않는 영역 $600\text{ m} \times 600\text{ m}$ 크기의 정방형 영상을 사용하였으며, 라벨값은 레이더로부터 약 6.7 km 떨어진 강문 AWS(Automatic Weather System)의 1분 단위 강우량 자료를 강우여부 자료로 보정하여 사용하였다(Fig. 2 가운데 그림). Table 2에 학습 데이터에 대한 정보를 나타내었다. 학습 데이터는 2019년 7월 1일에서 10월 3일까지의 레이더 영상 7,783개를 사용하였다. 수집한 레이더 영상 자료는 일반적으로 비강우 자료 비율이 크기 때문에 학습 데이터의 비율을 맞추주기 위해 강우 자료를 증식하였으며, 강우 샘플 3,422개, 비강우 샘플 4,361개를 학습에 사용하였다. 기계학습 이미지 분류에 널리 사용되는 공개 데이터셋인 CIFAR-10은 10개의 분류 클래스로 구성되며 각 클래스의 학습 데이터 개수는 5,000개이다. 강우/비강우 학습 샘플 개수가 이에 근접하므로 강우여부 분류 문제를 해결하기 위한 학습 데이터를 충분히 확보하였다고 판단된다.

한편 CNN 모델이 높은 분류 성능을 발휘하기 위해서는 학습 데이터 세트를 정교하게 구축하는 것이 매우 중요하다. 그




Fig. 3. Model structure of CNN rainfall classifier.

Table 2. Data for training and application of CNN

	Data period	2019.07.01.~2019.10.03.
Train Set		Total 7,783
	Data ratio	Rain sample 3,422 No-rain sample 4,361
Application Set	Data period	2018.11.23.~2020.09.20.
Label data		Gangmun AWS 1-minute rainfall data

려나 강문 AWS가 레이다 설치 지점으로부터 다소 떨어져 있어 레이다 영상에 나타난 강우 상황과 강수량 정보가 정확히 일치하지는 않기 때문에 CNN 모델 학습을 위한 라벨값으로 사용하기에 신뢰도가 다소 떨어지는 한계가 있다. 이를 보완하기 위하여 레이다 영상 학습 데이터 세트를 일차적으로는 강문 AWS의 강수량 자료를 기준으로 분류하였고, 분류된 영상을 직접 관찰하면서 수작업으로 조정하였다. 강우시 영상 중 픽셀 밝기의 평균값이 현저히 낮거나 비강우시 영상 중 밝기값 평균이 현저히 큰 경우는 학습 데이터에서 제외하였다. 제외 기준으로는 레이다 영상 밝기 평균값의 분포에서 임의로 적절히 선정한 값인 {평균 ± 1 s}(s는 표준편차) 값을 사용하였다. 라벨값인 강수량 자료는 비가 올 경우 1, 비가 오지 않을 경우 0을 나타내는 이진 데이터로 변환하여 학습용 라벨 값 데이터로 사용하였다.

2.5 인공신경망을 이용한 유의파고 추정

본 연구에서는 레이다 관측 자료와 유의파고 간의 비선형적 관계를 반영하여 유의파고를 추정하기 위한 방법으로 인공신경망(Artificial Neural Network, ANN) 모델을 사용하였다. ANN은 생물의 신경세포인 뉴런의 원리와 구조를 모사하여 개발된 기계학습 알고리즘의 하나이다. ANN은 입력층(input layer)과 은닉층(hidden layer) 그리고 출력층(output layer)으로 구성되어 있으며, 은닉층의 개수를 두 개 이상 사용할 수 있다. 모든 층의 각 노드(node)는 뉴런과 같이 서로 연결되어 있으며 각 노드로 들어오는 입력값에 가중치와 편향 및 활성화함수를 적용하여 출력값을 계산한다. ANN 모델 학습 과정에서 반복 계산과 오차역전파 등의 기술을 통해 각 노드의 최적의 가중치와 편향을 찾아 모델을 생성한다.

본 연구에서 신경망 구조는 순전파(Feedforward) 네트워크

를 사용하였고, 한 개의 은닉층으로만 구성하였다. 또한 MATLAB의 신경망 툴박스에서 제공하는 Levenberg-Marquardt backpropagation 함수를 사용하여 가중치와 편향의 최적값을 계산하였다. 유의파고 산정을 위한 ANN 모델 학습용 자료는 2019년 1월 1일부터 2020년 7월 31일 기간에 해당하는 파랑 정보와 풍속 자료를 입력 변수로 사용하였으며, 학습을 위한 기준값으로 경포대 해수욕장 인근 해상에 설치된 해양 관측부의 유의파고 자료를 보정하여 사용하였다. 학습하여 생성한 ANN 유의파고 산출 모델을 2020년 8월에서 9월 자료에 적용하여 태풍 마이삭과 하이선 내습시 유의파고 결과를 중심으로 검토하였다.

본 연구에서는 강우여부에 따라 ANN 모델 적용을 달리하여 강우시와 태풍시에 더 적합한 유의파고 추정 알고리즘을 제안하였으며, 강우여부를 고려하지 않고 단일 ANN 모델을 학습하여 유의파고를 산출하는 알고리즘의 결과와 비교하여 검토하였다.

3. 강우여부를 고려한 유의파고 산정 결과

3.1 CNN을 이용한 강우여부 분류 결과

강릉 안인 해안에서 2018년 11월 23일부터 2020년 9월 20일까지 수집한 79,843개의 X-band 레이다 영상의 강우여부를 분류한 결과와 정확도를 Table 3에 나타내었다. 비가 오는 경우를 P(positive)로 표기하여, 강우여부 분류 결과를 TP(true positive), FP(false positive), FN(false negative) 그리고 TN(true negative)로 구분하였다. 정확도는 TP와 TN의 합을 전체 분석 자료수로 나눈 값이며, 정확도를 계산한 자료에 학습 데이터의 일부 자료를 포함하였으며 이는 전체 분석 자료의 약 8% 정도이다.

Table 3. Results and accuracy of classification

	Number of data	Percentage (%)
True Positive (TP)	13,002	16.3
False Positive (FP)	4,519	5.7
False Negative (FN)	316	0.4
True Negative (TN)	62,006	77.7
Total population	79,843	100
Accuracy	$\frac{TP + TN}{Total\ Population} = \frac{75008}{79843}$	93.9

레이다 영상 강우여부 분류기의 분류 정확도는 93.9%이다. 이미지 분류 대회인 ILSVRC에서 최초로 인간의 오류율 (5.1%)보다 나은 성능으로 우수한 ResNet(He et al., 2016)의 정확도가 96.4%인 것을 고려할 때, 단순한 CNN 구조임에도 불구하고 강우여부 분류 성능이 비교적 좋은 것으로 평가된다. 분류 오류 6.1% 중 비가 오지 않았는데 온 것으로 분류한 False positive 경우가 5.7%를 차지하였는데, 이는 바람이 잘 불어 레이다 이미지 상에 파랑이 조밀하게 나타나는 경우를 강우시의 영상으로 인식하여 분류한 경우인 것으로 판단된다.

3.2 강우여부에 따른 ANN 모델의 적용성

ANN 기반 유의파고 추정 정확도는 레이다 영상의 품질과 입력 변수의 구성 등에 따라 달라진다. 강우여부에 따라 서로 다른 ANN 모델을 사용하기 위해 서로 다른 성능의 ANN 모델 두 가지를 학습하였고, 각각 ANN1과 ANN2로 표현하였다. 학습 자료의 기간은 2019년 1월 1일에서 2020년 7월 31일까지의 자료를 학습하여 모델을 생성하였으며, 학습한 모델을 2020년 8월에서 9월까지 약 2개월 자료에 적용하였다. Fig. 4에 2020년 8월에서 9월 자료를 ANN1과 ANN2 모델에 적용한 유의파고 시계열 결과를 부이 유의파고와 함께 나타내었다. 태풍 마이삭이 내습한 9월 3일경과 태풍 하이선이 내습한 9월 7일경의 유의파고 결과의 변화를 중점적으로 관찰하였다.

유의파고 산출을 위한 각 ANN 모델의 입력 변수와 샘플링 정보를 Table 4에 나타내었다. ANN1 모델은 Park et al. (2017)에서 사용한 ANN 기반 X-band 레이다 파고계의 입력 변수에서 몇 가지 변수를 더 추가한 모델로서, 레이다 영상으로부터 얻은 신호(signal), 잡음(noise), 신호대잡음비(SNR), 침두주기(Tp), 파향(Pdir), 그리고 풍속계에서 얻은 풍속(Ws) 자료를 입력 변수로 사용하였다. Park et al.(2020)은 낮은 풍속으로 인해 발생하는 유의파고 추정 오차를 보완하기 위해 레이더 영상의 품질을 평가하는 변수 $R_{val>k}$ 을 도입한바 있으며, 본 연구에서는 풍속을 직접 ANN의 입력변수로 하여 ANN 모델이 낮은 풍속으로 인한 영향을 반영하였다.

학습 자료는 일정 기간마다 등간격으로 하나씩 샘플링하였다. ANN1 모델은 일반적인 기상 상황에서 비교적 정확도 높은 유의파고 결과를 내지만 2020년 9월에 있었던 태풍 마이삭과 하이선 내습시에 오차가 크게 발생하였다. ANN2는 태풍 및 강우시에 적합하도록 입력 변수를 조정하고 학습 데이터 샘플링 방법을 달리하여 학습한 모델이다. 강우시에 오염되는 잡음(noise) 변수를 배제하고, 전체 데이터 중 풍속 자료의 비중을 높였다. 태풍시는 유의파고에 급격한 변동이 발생하는 시점이기 때문에 극값 자료를 학습 데이터에 포함하기 위해 일정 기간 내 최대, 최소값을 학습 자료로 샘플링하였다. ANN2는 태풍 마이삭과 하이선 내습시 ANN1의 결과보다 정확도 높은 유의파고를 결과를 나타내었다.

강우여부에 따라 각 ANN 모델을 적용한 유의파고 결과와

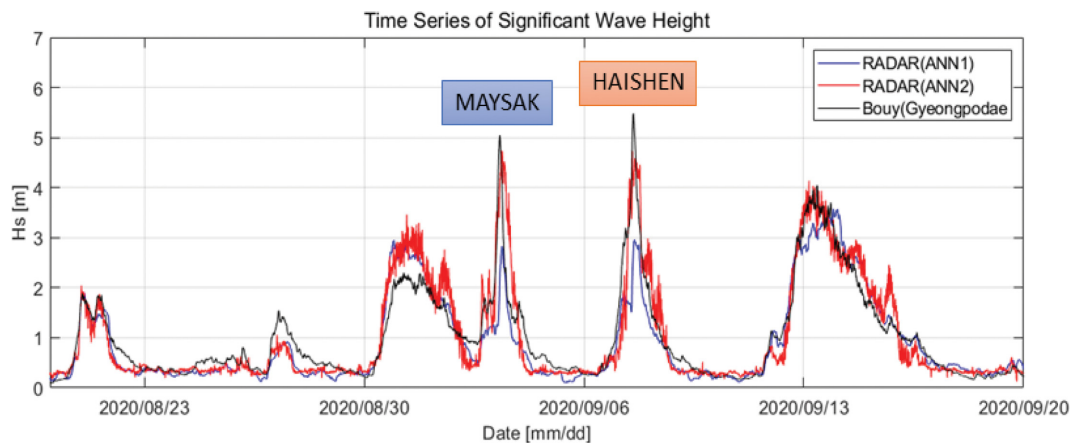


Fig. 4. Time series significant wave heights (Hs) for ANN1 and ANN2 with the reference buoy.

Table 4. Train information of ANN1 and ANN2

ANN1	Input parameters	Signal, Noise, SNR, Tp, Pdir, Ws, and Max/Min value of each parameter for past 6 hours
	Sampling	Equal interval sampling within 2019.01.01.~2020.07.31.
ANN2	Input parameters	Signal, SNR, Tp, Ws, and Max/Min value of Ws for past 6 hours
	Sampling	Local Max/Min sampling within 2019.01.01.~2020.07.31.




Fig. 5. Hs results for no-rain cases.




Fig. 6. Hs results for rain cases.




Fig. 7. Hs results of the old algorithm.




Fig. 8. Hs results of the proposed algorithm.

경포대해수욕장 부이 유의파고를 비교한 결과를 Fig. 5와 Fig. 6에 나타내었으며, 이는 각각 비강우와 강우시의 결과를 차례로 나타낸다. Fig. 5에서 비강우 자료의 경우 ANN2를 적용한 저파랑 자료의 일부가 과대평가 되는 경향이 나타난다. 이는 ANN2가 급격히 변하는 자료를 중심으로 학습한 모델이므로 파고가 낮은 평상시의 자료에서 과대평가되는 것으로 판단된다. 반면 Fig. 6에서는 강우 자료의 경우 ANN1을 적용한 고파랑 자료의 일부가 과소평가 되는 경향이 나타난다. 이는 ANN1 모델이 평상시의 저파랑 자료를 중심으로 학습한 모델이기 때문인것으로 판단된다.

3.3 강우여부를 고려한 유의파고 산정 결과

3.2절에서 강우여부에 따라 ANN 모델의 적용성이 다르게 나타남을 확인하였다. 따라서 비강우 자료일 경우 ANN1 모델을, 강우 자료일 경우 ANN2 모델을 선택 및 적용하여 유의파고를 산출하였다. Fig. 7은 강우여부를 구분하지 않고 ANN1 모델을 적용한 유의파고 결과이고 Fig. 8은 강우여부에 따라 ANN 모델을 선택적으로 적용하여 산출한 최종 유의파고 결과이며, 각각 부이 유의파고와의 상관성을 나타낸다. 강우여부를 고려하여 ANN을 적용한 결과, 결정계수가 0.88에서 0.90로 소폭 증가하였으며 과소평가 되었던 태풍시 또는

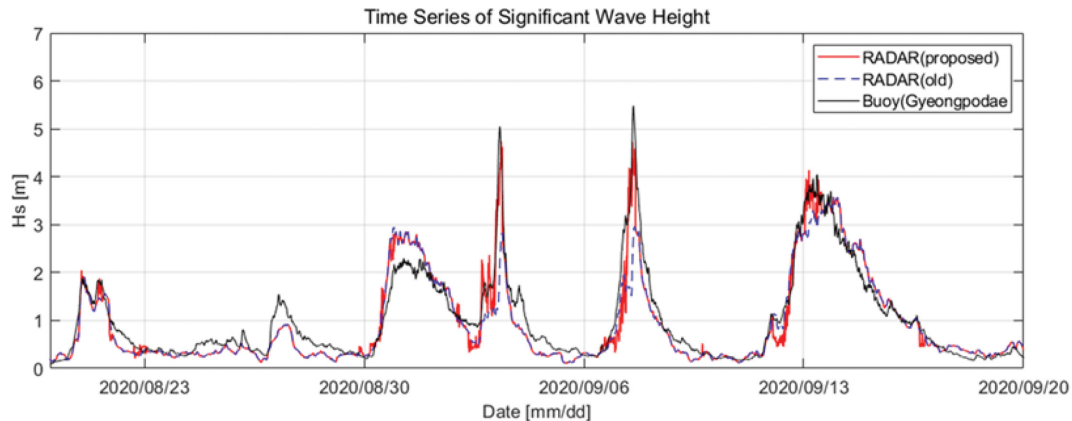


Fig. 9. Time series of significant wave heights (Result of proposed Hs estimation model).

강우시의 고파랑 자료가 보정이 되는 것을 확인할 수 있다.

Fig. 9는 최종 유의파고의 시계열 결과를 기존 알고리즘 결과 및 부이 유의파고와 함께 나타낸 것이다. 평상시와 태풍 마이삭과 하이선의 경우 모두 유의파고 산정 정확도가 개선된 것으로 판단된다. 오차가 다소 발생하는 태풍 하이선의 경우 태풍이 통과한 직후 비가 그친 것을 확인하였으며, 비가 그친 시점 이후에도 풍속이 빠르고 높은 유의파고가 관측되었지만 비강우에 적합한 ANN 모델이 적용된 것으로 보인다. 향후 이러한 문제를 고려하여 태풍과 같은 악기상시에 강우 전후에 발생하는 고파랑 자료에 대해 유의파고 관측 성능을 개선하는 연구가 필요할 것으로 판단된다.

4. 결 론

CNN을 이용해 X-band 레이다 이미지로부터 강우여부를 분류하였고 그 결과를 X-band 레이다 파고계의 인공신경망 모델에 적용하여 실시간 유의파고 산정이 가능한 ANN 모델 기반 유의파고 추정 알고리즘을 제안하였다. CNN 모델을 이용하여 X-band 레이다 영상의 강우잡음 여부 분류가 가능함을 확인하였고 분류 정확도는 93.9%를 나타내었다. 6.1%의 오분류된 자료들을 확인한 결과, 비강우시 자료임에도 레이다 영상에 파랑이 조밀하게 나타나서 강우시의 잡음과 비슷하게 판단되어 강우 자료로 오분류한 경우가 대부분의 오차를 차지하였다. 학습 데이터셋을 수작업으로 조정하여 정확도를 높은 수준까지 향상시켰으나, 학습 데이터셋에 비강우시 파랑이 잘 나타난 레이다 영상 자료의 비율을 높임으로써 이러한 오분류를 줄일 수 있을 것으로 판단된다. 또한 강우여부에 따라 유의파고 산출을 위한 ANN 모델을 서로 다르게 적용한 결과, 강우여부를 고려하지 않고 단일 모델만으로 유의파고를 산출하는 기존 알고리즘보다 강우시 또는 태풍시에 상당히 개선된 유의파고 결과를 나타내었다. 제안된 알고리즘의 유의파고 결과와 경포대 해수욕장 해양관측부이 유의파고 자료의 상관성을 분석한 결과 결정계수는 0.88에서 0.90로 소폭 상승하였다. 이는 주로 개선된 자료가 강우시 자료

인데 전체 자료에서 차지하는 비율은 작기 때문에 수치적인 변화는 크지 않은 것으로 판단된다. 특히 과소평가되었던 태풍시 및 강우시의 고파랑 자료가 보정된 것을 확인하였다.

제안한 알고리즘은 강우여부만을 기준으로 선정하여 서로 다른 ANN 모델을 적용하여 유의파고를 산정하였다. 그러나 강우를 동반하지 않은 태풍이나 악기상 조건에서도 안정적으로 유의파고를 계산할 수 있도록 강우여부 뿐 아니라 태풍예보 유무 등의 정보를 추가적으로 고려하는 것이 좋을 것으로 판단된다. 한편, 주기와 파향은 유의파고 산정에 사용되어 유의파고 정확도에 영향을 미치며, 최근 동해안에서 너울성 고파랑에 의한 피해 사례가 증가하고 있으므로 추후 레이다 파고계로 관측한 주기와 파향에 대해서 검증할 필요가 있을 것으로 판단된다.

감사의 글

본 연구는 해양수산부의 해양과학조사 및 예보 기술사업의 일환인 “연안이상현상(이상고파, 이안류) 발생원인 규명 및 대응체계 구축”(NO.20140057) 연구비 지원으로 수행되었습니다.

References

- Ahn, K., Chun, J. and Cheon, S.H. (2014). New calibration method applicable to significant wave heights obtained by X-band radar. *Coastal Engineering Proceedings*, (34), 15-15.
- Alpers, W. and Hasselmann, K. (1982). Spectral signal to clutter and thermal noise properties of ocean wave imaging synthetic aperture radars. *International Journal of Remote Sensing*, 3(4), 423-446.
- Gomez, R., Helzel, T., Petersen, L., Kniephoff, M., Merz, C.R., Liu, Y. and Weisberg, R.H. (2014). Real-time quality control of current velocity data on individual grid cells in WERA HF radar. *Oceans 2014-Taipei*, IEEE, 1-7.
- Gurgel, K.W., Schlick, T., Voulgaris, G., Seemann, J. and Ziemer, F. (2011). HF radar observations in the German Bight: Measurements and quality control. *IEEE*, 51-56.

- He, K., Zhang, X., Ren, S. and Sun, J. (2016). Deep residual learning for image recognition. In Proceedings of the IEEE conference on computer vision and pattern recognition (pp. 770-778).
- Hisaki, Y. (2009). Quality control of surface wave data estimated from low signal-to-noise ratio HF radar Doppler spectra. *Journal of Atmospheric and Oceanic Technology*, 26(11), 2444-2461.
- Huang, N.E., Shen, Z., Long, S.R., Wu, M.C., Shih, H.H., Zheng, Q., Yen, N., Tung, C.C. and Liu, H.H. (1998). The empirical mode decomposition and the Hilbert spectrum for nonlinear and non-stationary time series analysis. *Proceedings of the Royal Society of London. Series A: Mathematical, Physical and Engineering Sciences*, 454(1971), 903-995.
- Jun, H., Min, Y., Jeong, J.Y. and Do, K. (2020). Measurement and Quality Control of MIROS Wave Radar Data at Dokdo. *Journal of Korean Society of Coastal and Ocean Engineers*, 32(2), 135-145.
- Liu, X., Huang, W. and Gill, E.W. (2016a). Wind direction estimation from rain-contaminated marine radar data using the ensemble empirical mode decomposition method. *IEEE Transactions on Geoscience and Remote Sensing*, 55(3), 1833-1841.
- Liu, X., Huang, W. and Gill, E.W. (2016b). Wave height estimation from shipborne X-band nautical radar images. *Journal of Sensors*, 2016.
- Nieto Borge, J., Rodríguez, G.R., Hessner, K. and González, P.I. (2004). Inversion of marine radar images for surface wave analysis. *Journal of Atmospheric and Oceanic Technology*, 21(8), 1291-1300.
- Park, J.S., Ahn, K. and Oh, C.Y. (2017). Calibration of Significant Wave Height Obtained by X-band Radar using Artificial Neural Networks, *Proceedings of Coastal and Ocean Engineering in Korea*, 25, 132-135.
- Park, J., Ahn, K., Oh, C. and Chang, Y.S. (2020). Estimation of significant wave heights from x-band radar using artificial neural network. *Journal of Korean Society of Coastal and Ocean Engineers*, 32(6), 561-568.
- Vicen-Bueno, R., Lido-Muela, C. and Nieto-Borge, J.C. (2012). Estimate of significant wave height from non-coherent marine radar images by multilayer perceptrons. *EURASIP Journal on Advances in Signal Processing*, 2012(1), 84.

Received 9 June, 2021

Revised 14 June, 2021

Accepted 14 June, 2021